

# Diseño y desarrollo de un agente negociador para la competición de Werewolf de la ANAC2019

Ramon Ruiz-Dolz, Javier Iranzo-Sanchez

Institut Valencià d'Investigació en Intel·ligència Artificial

April 25, 2019



UNIVERSITAT  
POLITÈCNICA  
DE VALÈNCIA



- 1 Introducción
  - Dominio
  - Objetivos
- 2 Modelado de oponentes
- 3 Sistema argumentativo
  - Formalización del marco argumentativo
  - Instanciación del marco argumentativo
- 4 Heurística de negociación
  - Equipo Aldeanos
  - Equipo Werewolf
- 5 Resultados
- 6 Conclusiones

## 1 Introducción

- Dominio
- Objetivos

## 2 Modelado de oponentes

## 3 Sistema argumentativo

- Formalización del marco argumentativo
- Instanciación del marco argumentativo

## 4 Heurística de negociación

- Equipo Aldeanos
- Equipo Werewolf

## 5 Resultados

## 6 Conclusiones

# Dominio del Problema

- Juego de **roles ocultos**
- Dos equipos: Mayoría desinformada (**aldeanos**) y minoría informada (**hombres-lobos**)
- **Aldeanos**: Cada día votan linchar a una personal del pueblo, en un intento desesperado de acabar con los lobos.
- **Hombres-lobos**: Cada noche, los lobos salen de caza y se ponen de acuerdo para matar a un aldeano.
- **Carrera contrareloj** para los aldeanos, no se revelan roles al morir.

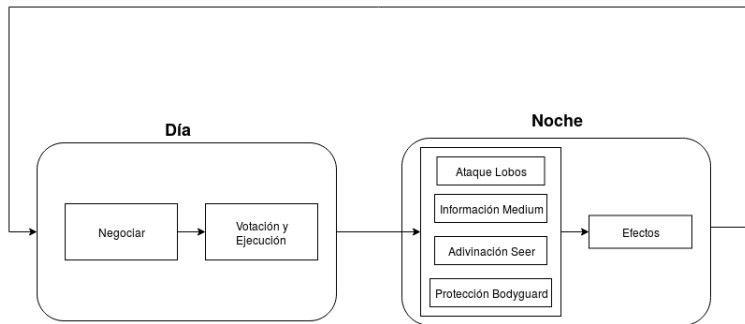


Figure 1: Esquema del desarrollo de una partida de Werewolf

- Implementación de un agente negociador para la ANAC2019 (Werewolf)
- Inferir información oculta mediante el modelizado de oponentes
- Diseño de un marco argumentativo capaz de gestionar el flujo de mensajes de forma coherente (AIWolf)
- Implementación de heurísticas de negociación adecuadas para el dominio escogido

- 1 Introducción
  - Dominio
  - Objetivos
- 2 Modelado de oponentes
- 3 Sistema argumentativo
  - Formalización del marco argumentativo
  - Instanciación del marco argumentativo
- 4 Heurística de negociación
  - Equipo Aldeanos
  - Equipo Werewolf
- 5 Resultados
- 6 Conclusiones

- A partir de los eventos de una partida,  $x_1^N$ , asignar un rol  $r$  a cada jugador  $j$ .

$$p(y_j = r_m | x_1^N) \quad \forall j \in J \quad \forall m \in R \quad (1)$$

- Asumimos independencia entre los roles:

$$p(y_1^J | x_1^N) := \prod_{j=1}^J p(y_j | x_1^N) \quad (2)$$

- Representación de una secuencia: Suma de representaciones de sus elementos [3]
- Evento: La acción/performativa ejecutada en cada momento.



# Experimentos

1 modelo (regresión logística) por cada agente




Figure 2: Medida F1 (macro) en función del número de partidas observadas.

# Experimentos




Figure 3: Rendimiento del modelo en función del tiempo transcurrido de partida

# Experimentos




Figure 4: Rendimiento del modelo genérico en función del número de partidas

- 1 Introducción
  - Dominio
  - Objetivos
- 2 Modelado de oponentes
- 3 Sistema argumentativo
  - Formalización del marco argumentativo
  - Instanciación del marco argumentativo
- 4 Heurística de negociación
  - Equipo Aldeanos
  - Equipo Werewolf
- 5 Resultados
- 6 Conclusiones

Tomando el marco de argumentación abstracta basada en valores propuesto en [1, 2] como punto de partida se propone,

## Definition (Trust-Based Argumentation Framework)

Nuestro marco argumentativo consiste en una tupla  $\langle A, R, \delta, P \rangle$  donde  $A$  consiste en el conjunto de argumentos,  $R$  consiste en el conjunto de relaciones sobre  $A$ ,  $\delta$  es un factor de puntuación basado en la confianza para cada argumento dado un agente determinado y  $P$  es el conjunto de agentes involucrados en la argumentación.

# Instanciación del marco argumentativo

- **Argumentos ( $A$ ):**

$\forall \alpha \in A, \alpha = (claim, support)$  donde *claim* es la conclusión del argumento y *support* es su soporte.

- **Relaciones ( $R$ ):**

$\exists r(\alpha_i, \alpha_j) \iff claim_i \neq claim_j$ . En otras palabras, existirán relaciones de ataque entre todos los argumentos cuyo *claim* sea diferente.

- **Puntuación basada en la confianza ( $\delta$ ):**

$$\delta(\alpha, p) = \frac{1}{n_p + 1} \quad (3)$$

donde  $n_p$  es el número de mentiras realizadas por el agente  $p \in P$ .

- **Agentes ( $P$ ):**

Finalmente el parámetro  $P$  del marco argumentativo consiste en una lista de todos los agentes que hayan participado en la conversación de un día determinado aportando como mínimo un argumento al diálogo.

- 1 Introducción
  - Dominio
  - Objetivos
- 2 Modelado de oponentes
- 3 Sistema argumentativo
  - Formalización del marco argumentativo
  - Instanciación del marco argumentativo
- 4 **Heurística de negociación**
  - **Equipo Aldeanos**
  - **Equipo Werewolf**
- 5 Resultados
- 6 Conclusiones

# Heurística basada en la detección de mentiras: Aldeanos

- Si tiene rol único comprueba que nadie más revele ser ese rol
- Busca incongruencias entre los mensajes emitidos durante la conversación (e.g. dos revelaciones distintas por parte de un mismo agente)
- Si es acusado como miembro del equipo contrario
- Conan(SEER), Bob(POSSESSED):

**Conan:** DIVINED BOB POSSESSED

**Bob:** COMINGOUT BOB SEER

**Conan:** BECAUSE (AND (COMINGOUT BOB SEER) (DIVINED BOB POSSESSED)) (REQUEST(VOTE BOB))



# Heurística basada en la detección de mentiras: Werewolf

- Busca incongruencias entre los mensajes emitidos durante la conversación (e.g. dos revelaciones distintas por parte de un mismo agente) cuya fuente no sea compañero de equipo
- Si es acusado como miembro del equipo Werewolf
- Conan(POSSESSED), Bob(VILLAGER):

**Bob:** DIVINED CONAN POSSESSED

**Conan:** BECAUSE (DIVINED CONAN POSSESSED) (REQUEST(VOTE BOB))

- 1 Introducción
  - Dominio
  - Objetivos
- 2 Modelado de oponentes
- 3 Sistema argumentativo
  - Formalización del marco argumentativo
  - Instanciación del marco argumentativo
- 4 Heurística de negociación
  - Equipo Aldeanos
  - Equipo Werewolf
- 5 Resultados
- 6 Conclusiones

# Resultados (I)

Primer experimento contra agentes de muestra (SampleAgent):

- Tercera posición
- 64% de partidas ganadas en el equipo WW (WW+PS)
- 36% de partidas ganadas en total

	BG	MD	PS	SE	VL	WW	TOTAL
Sample3	1/6	1/6	13/14	2/9	7/46	17/19	0.410
Sample7	2/4	4/12	8/9	0/8	5/47	18/20	0.370
<b>DetectiveConan</b>	<b>0/7</b>	<b>0/5</b>	<b>9/13</b>	<b>0/4</b>	<b>8/50</b>	<b>19/21</b>	<b>0.360</b>
Sample1	1/7	0/5	4/6	2/6	6/50	23/26	0.360
Sample14	1/7	1/9	5/5	0/2	11/58	18/19	0.360
Sample2	1/5	1/3	4/4	1/8	10/60	19/20	0.360
Sample8	0/9	1/7	6/6	2/6	6/47	20/25	0.350
Sample12	1/8	1/4	6/6	1/6	8/56	17/20	0.340
Sample11	3/7	1/5	8/8	1/11	6/52	14/17	0.330
Sample4	0/4	1/7	5/8	2/8	7/55	17/18	0.320
Sample13	1/3	2/8	6/6	0/5	8/62	13/16	0.300
Sample9	1/7	0/6	3/4	1/9	8/55	16/19	0.290
Sample5	0/9	0/8	1/1	0/8	10/53	17/21	0.280
Sample6	1/9	0/6	2/4	2/5	6/56	17/20	0.280
Sample10	1/8	1/9	6/6	0/5	6/53	13/19	0.270

# Resultados (II)

Segundo experimento con todos los agentes iguales (DetectiveConan):

- 80% de partidas ganadas en el equipo WW (WW+PS)
- 33% de partidas ganadas en el equipo aldeano

	BG	MD	PS	SE	VL	WW
DetectiveConan	20/100	20/100	80/100	20/100	160/800	240/300

- 1 Introducción
  - Dominio
  - Objetivos
- 2 Modelado de oponentes
- 3 Sistema argumentativo
  - Formalización del marco argumentativo
  - Instanciación del marco argumentativo
- 4 Heurística de negociación
  - Equipo Aldeanos
  - Equipo Werewolf
- 5 Resultados
- 6 Conclusiones

- Evaluación compleja
- Buen comportamiento en el equipo de los hombres-lobo (mayor peso de la argumentación)
- Gran dependencia en el comportamiento de los demás agentes
- Decisiones aleatorias si no existe interacción por parte de los demás agentes

- Integración del estimador de roles en el agente
- Minimizar la aleatoriedad en la toma de decisiones







Trevor Bench-Capon.

Value based argumentation frameworks.

*arXiv preprint cs/0207059*, 2002.



Trevor JM Bench-Capon.

Persuasion in practical argument using value-based argumentation frameworks.

*Journal of Logic and Computation*, 13(3):429–448, 2003.



Quoc V. Le and Tomas Mikolov.

Distributed representations of sentences and documents.

In *Proceedings of the 31th International Conference on Machine Learning, ICML 2014, Beijing, China, 21-26 June 2014*, pages 1188–1196, 2014.